МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МО ЭВМ

ОТЧЕТ

по лабораторной работе №5
по дисциплине «Искусственные нейронные сети»
Тема: Распознавание объектов на фотографиях

Студент гр. 7383	 Бергалиев М
Преподаватель	 Жукова Н.А.

Санкт-Петербург

2020

Цель работы: Реализовать классификацию небольших изображений по десяти классам: самолет, автомобиль, птица, кошка, олень, собака, лягушка, лошадь, корабль и грузовик

Порядок выполнения работы.

- 1. Построить и обучить сверточную нейронную сеть
- 2. Исследовать работу сеть без слоя Dropout
- 3. Исследовать работу сети при разных размерах ядра свертки

Ход работы.

- 0. Исходный код программы представлен в приложении.
- 1. Выберем модель сети. Возьмем два сверточных слоя с 32 фильтрами с размером ядра свертки 3х3 с активацией relu, слой субдискретизации тахрооling с размером 2х2, слой разреживания dropout с вероятностью 0.2, два сверточных слоя с 64 фильтрами с размером ядра свертки 3х3 с активацией relu, слой субдискретизации тахрооling с размером 2х2, слой разреживания dropout с вероятностью 0.2, два сверточных слоя с 128 фильтрами с размером ядра свертки 3х3 с активацией relu, слой субдискретизации тахрооling с размером 2х2, слой разреживания dropout с вероятностью 0.2, слой с 512 нейронами с активацией relu, слой разреживания dropout с вероятностью 0.5 и выходной слой с 10 нейронами с активацией softmax. В качестве оптимизатора будем использовать SGD со скоростью обучения 0.1. Будем обучать 25 эпох с размером батча 100. Ошибка и точность во время обучения показаны на рис. 1, 2.

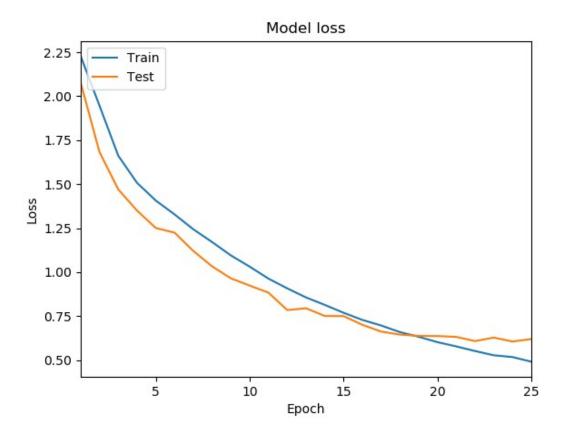


Рисунок 1 — График ошибок во время обучения модели

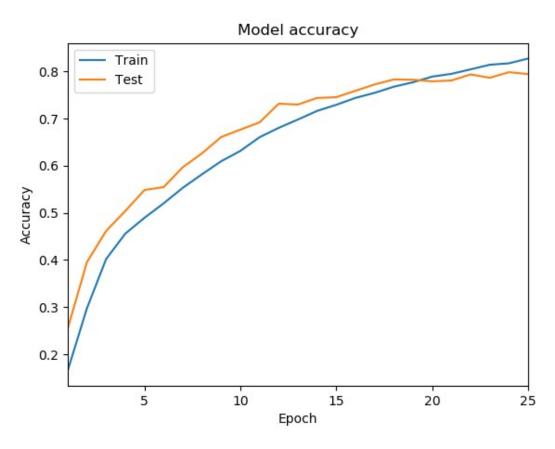


Рисунок 2 — График точности во время обучения модели

На проверочном наборе точность составила 80%.

2. Обучим модель без слоя разреживания. Результаты показаны на рис. 3-4.

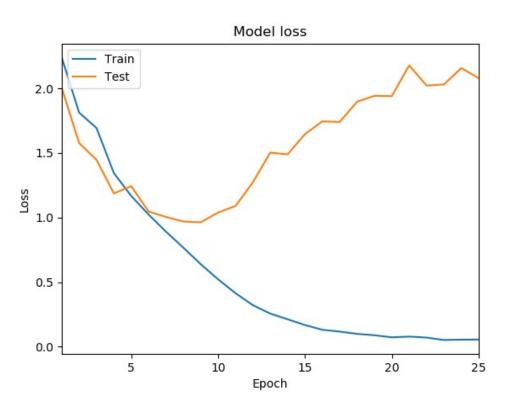


Рисунок 3 — График ошибок во время обучения модели без dropout

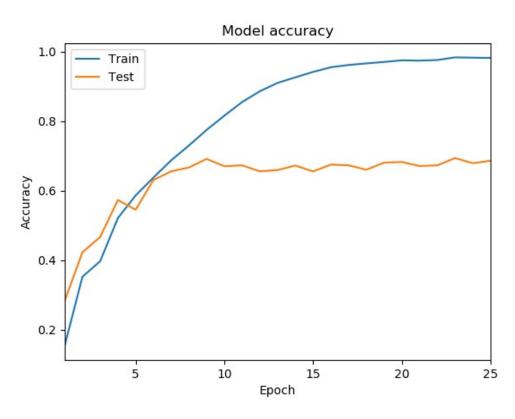


Рисунок 4 — График точности во время обучения модели без dropout

Как видно, после 9-ой эпохи начинается переобучение. Поэтому необходимо использование слоя разреживания. На проверочном наборе точность составила 67%.

3. Обучим модель с различными размерами ядра свертки. Результаты для размеров 2x2, 5x5, 7x7 показаны на рис. 5-10.

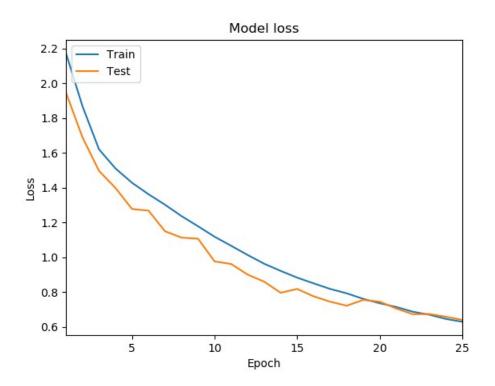
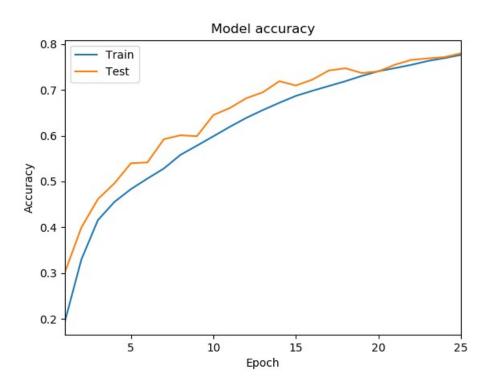


Рисунок 5 — График ошибок при размере ядра свертки 2х2



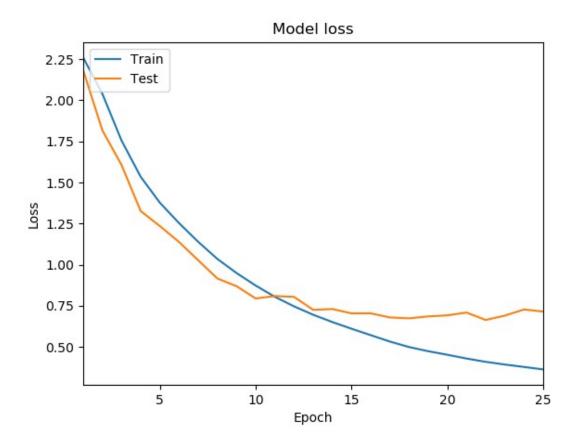
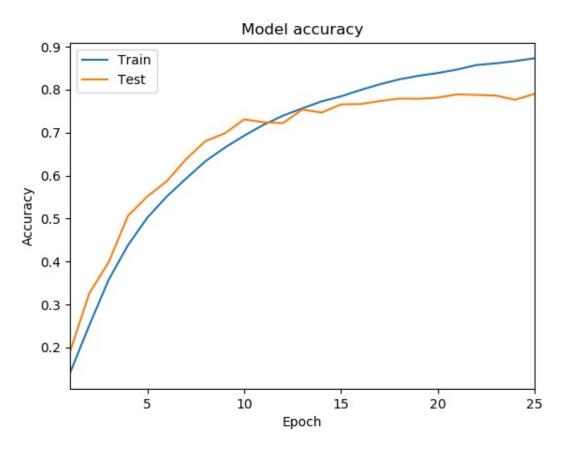


Рисунок 7 — График ошибок при размере ядра свертки 5х5



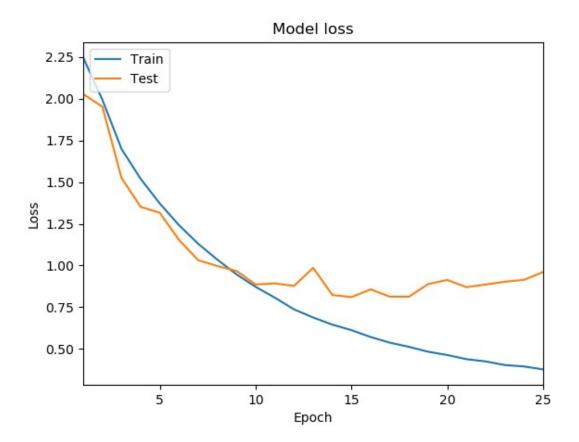


Рисунок 9 — График ошибок при размере ядра свертки 7х7

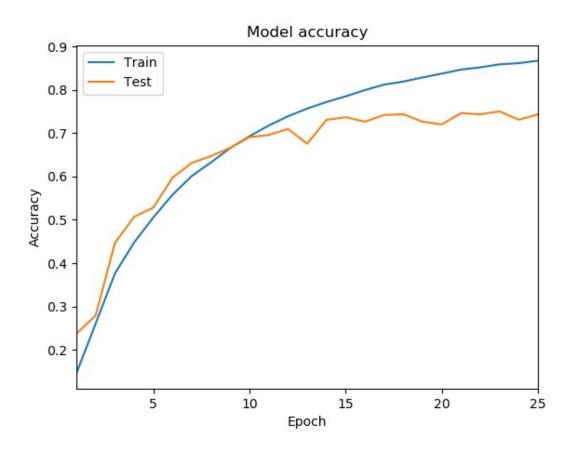


Рисунок 10 — График точности при размере ядра свертки 7х7

Как видно, с увеличением размера ядра свертки при неизменных остальных параметров сети переобучение возникает раньше, а точность падает. Для достижения лучших результатов нужно менять и другие параметры модели. На проверочном наборе точность составила 76%, 77% и 72% соотвественно.

Выводы: Было изучено влияние слоя разреживания на результат обучения. Данный слой помогает бороться с проблемой переобучения. При изменении размера ядра свертки необходимо корректировать всю модель.

ПРИЛОЖЕНИЕ

```
from tensorflow.keras.datasets import cifar10
      tensorflow.keras.layers
                                  import
                                            Input, Convolution2D,
MaxPooling2D, Dense, Dropout, Flatten
from tensorflow.keras.models import Model
from tensorflow.keras.optimizers import SGD
from keras.utils import to categorical
import numpy as np
import matplotlib.pyplot as plt
from time import sleep
(X train, y train), (X test, y test) = cifar10.load data()
num train, width, height, depth = X train.shape
num test = X test.shape[0]
num classes = np.unique(y train).shape[0]
X train = X train.astype('float32')
X test = X test.astype('float32')
X train /= 255.0
X \text{ test } /= 255.0
Y train = to categorical(y train, num classes)
Y test = to categorical(y test, num classes)
batch size = 100
num epochs = 25
pool size = 2
conv depth 1 = 32
conv depth 2 = 64
conv depth 3 = 128
drop prob 1 = 0.2
drop prob 2 = 0.5
hidden size = 512
def build model(kernel size=3, with dropout=True):
    inp = Input(shape=(width, height, depth))
           conv 1 = Convolution2D(conv depth 1, (kernel size,
kernel size),
                                     padding='same', strides=(1,1),
activation='relu')(inp)
           conv 2 = Convolution2D(conv depth 1, (kernel size,
kernel size),
                                 padding='same', activation='relu')
(conv 1)
        pool 1 = MaxPooling2D(pool size=(pool size, pool size))
(conv 2)
    if with dropout:
        drop 1 = Dropout(drop prob 1) (pool 1)
```

```
else:
        drop 1 = pool 1
           conv 3 = Convolution2D(conv_depth_2, (kernel_size,
kernel size),
                                    padding='same', strides=(1,1),
activation='relu') (drop 1)
           conv 4 = Convolution2D(conv depth 2, (kernel size,
kernel size),
                                    padding='same', strides=(1,1),
activation='relu') (conv 3)
        pool 2 = MaxPooling2D(pool size=(pool size, pool size))
(conv 4)
    if with dropout:
        drop 2 = Dropout(drop prob 1) (pool 2)
    else:
        drop 2 = pool 2
           conv 5 = Convolution2D(conv depth 3, (kernel size,
kernel size),
                                    padding='same', strides=(1,1),
activation='relu') (drop 2)
           conv_6 = Convolution2D(conv_depth_3, (kernel_size,
kernel size),
                                    padding='same', strides=(1,1),
activation='relu') (conv 5)
        pool 3 = MaxPooling2D(pool size=(pool size, pool size))
(conv 6)
    if with dropout:
        drop 3 = Dropout(drop prob 1) (pool 3)
    else:
        drop 3 = pool 3
    flat = Flatten()(drop 3)
    hidden = Dense(hidden size, activation='relu')(flat)
    if with dropout:
        drop 4 = Dropout(drop prob 2)(hidden)
    else:
        drop 4 = hidden
    out = Dense(num classes, activation='softmax') (drop 4)
    model = Model(inp, out)
    model.compile(loss='categorical crossentropy',
                  optimizer=SGD(0.1),
                  metrics=['accuracy'])
    return model
def plot res(history, label):
    x = range(1, num epochs+1)
    plt.plot(x, history.history['loss'])
```

```
plt.plot(x, history.history['val loss'])
    plt.title('Model loss')
    plt.ylabel('Loss')
    plt.xlabel('Epoch')
    plt.xlim(x[0], x[-1])
    plt.legend(['Train', 'Test'], loc='upper left')
    plt.savefig(label+' loss.png')
    plt.clf()
    plt.plot(x, history.history['accuracy'])
    plt.plot(x, history.history['val accuracy'])
    plt.title('Model accuracy')
    plt.ylabel('Accuracy')
    plt.xlabel('Epoch')
    plt.xlim(x[0], x[-1])
    plt.legend(['Train', 'Test'], loc='upper left')
    plt.savefig(label+'_acc.png')
    plt.clf()
def test model():
    model = build model()
    history = model.fit(X train, Y train,
              batch size=batch size, epochs=num epochs,
              verbose=1, validation split=0.1)
    res = model.evaluate(X test, Y test, verbose=0)
    print(res)
    plot res(history, 'best')
def test without dropout():
    model = build model(with dropout=False)
    history = model.fit(X train, Y train,
              batch size=batch size, epochs=num epochs,
              verbose=1, validation split=0.1)
    res = model.evaluate(X test, Y test, verbose=1)
    print(res)
    plot_res(history, 'without_dropout')
def test kernel size():
    for k in [2, 5, 7]:
        model = build model(k)
        history = model.fit(X train, Y train,
              batch size=batch size, epochs=num epochs,
              verbose=1, validation split=0.1)
        res = model.evaluate(X test, Y test, verbose=1)
        print (res)
        plot res(history, str(k))
```

```
def main():
    test_model()
    test_without_dropout()
    test_kernel_size()

if __name__ == '__main__':
    main()
```